

**AGH**

AKADEMIA GÓRNICZO-HUTNICZA  
IM. STANISŁAWA STASZICA W KRAKOWIE

# Inżynierskie techniki obliczeniowe 2021/2022

**Wykład nr 5**

**Dr inż. Przemysław Korohoda**  
**E-mail: korohoda@agh.edu.pl**  
**Tel.wewn.AGH: (012-617)-27-52**  
**Pawilon C3 - p.506**

**Strona WWW:**

**[home.agh.edu.pl/~korohoda/rok\\_2021\\_2022\\_lato/ITO\\_EL\\_1](http://home.agh.edu.pl/~korohoda/rok_2021_2022_lato/ITO_EL_1)**

**UPeL: ITOEL2022**

# Plan wykładu

1. Generowanie pseudolosowe.
2. Modelowanie zależności - regresja liniowa.
3. Modelowanie zależności - regresja nieliniowa.



# Rozkład (gęstości zmiennej losowej) AGH równomierny o zadanych parametrach

Równomierny rozkład gęstości prawdopodobieństwa  
zmiennej losowej, określonej na odcinku

$D=[x_0, x_1) : (x_1 - x_0) = \Delta x$ :

$$x_a, x_b \in D : P(X \in [x_a, x_b)) = \int_{x_a}^{x_b} f(x) dx = \frac{(x_b - x_a)}{\Delta x}$$


```
... N=2^10; u=3; r=2;  
x=(rand(N,1)-0.5)*2*r+u;
```

```
s = std(x),  
m = mean(x),  
K=30;  
[hx,bx] = hist(x,K);
```


```
figure(1); clf;  
bar(bx,hx,1); grid on;  
xlim([u-r,u+r]);
```

```
...
```


**K=10:**



**K=30:**



**K=100:**



Inne pokrewne funkcje: **histcounts**, **histogram**.

# Porównanie PDF z histogramem



Należy pamiętać o normalizacji.

```
...
N=2^10; u=3; r=2;
x = (rand(N,1)-0.5)*2*r+u;

s = std(x),
m = mean(x),
K=30;
[hx,bx] = hist(x,K);    dx=bx(2)-bx(1);
y1=1/(2*r);            q=sum(hx)*dx;

figure(1); clf;
bar(bx,hx,1);          grid on;    hold on;

plot([bx(1),bx(end)],[y1,y1]*q,'r','linewidth',3);
xlim([u-r,u+r]);
...
```



**Uwaga – tu normalizacja do pdf'a**


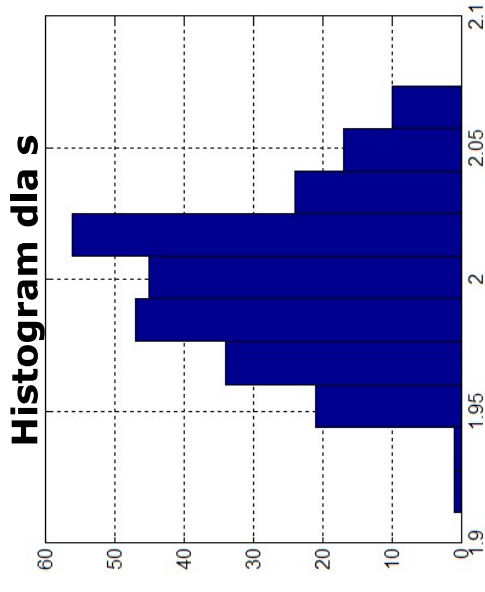


# Rozkłady z próby dla wartości średniej AGH i odchylenia standardowego

Są to także zmienne losowe!  
Zatem mają prawo mieć rozkłady  
(tzw. pdf'y)...

```
... M=2^8; % liczba losowan;  
N=2^10; u=3; sigma=2;  
X=(rand(N,M)-0.5)*sqrt(12)*sigma+u;  
  
s = std(X), % dziala na kolumnach macierzy;  
m = mean(X), % dziala na kolumnach macierzy;  
K=10;  
[hs,bs]=hist(s,K);  
[hm,bm]=hist(m,K);  
...
```

... i te rozkłady też mają swoje parametry!



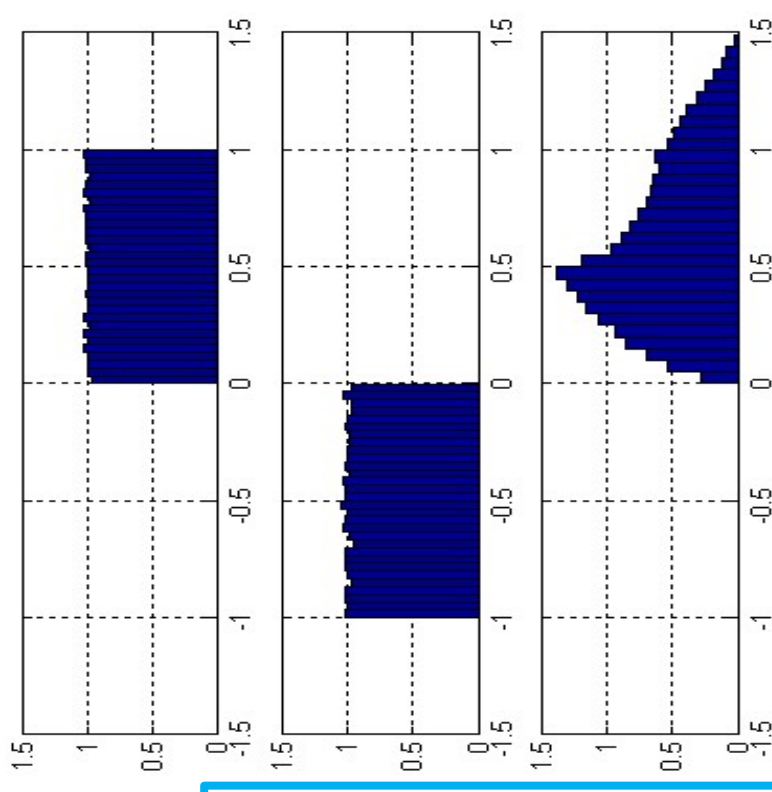


AGH

# Zmienna losowa otrzymana z innych zmiennych losowych (cd.)

$$Y(\mu_3, \sigma_3) = \frac{1}{2} \cdot X_1(\mu_1, \sigma_1) + [X_2(\mu_2, \sigma_2)]^2$$

Rozkłady (pdf) otrzymane z próby:



```
... N=2^16; % liczność próby losowej;  
x1=(rand(N,1)-0.5) + 0.5;  
x2=(rand(N,1)-0.5) - 0.5;  
y=0.5*x1 + x2.^2;  
sx1 = std(x1), mx1 = mean(x1),  
sx2 = std(x2), mx2 = mean(x2),  
sy = std(y), my = mean(y),  
  
K=30;  
[hx1,bx1] = hist(x1,K);  
[hx2,bx2] = hist(x2,K);  
[hy,by] = hist(y,K);  
...
```

# Wtórne (pochodne) zmienne losowe

Wartość średnia z próby:

$$m = \frac{1}{n} \cdot \sum_{i=1}^n x_i \approx \mu$$

Odchylenie standardowe z próby:

$$s_0 = \sqrt{\frac{1}{n} \cdot \sum_{i=1}^n (x_i - m)^2} \approx \sigma$$

estymator obciążony

...  
s1 = std(x),  
s2 = std(x,1),  
...

$$s_1 = \sqrt{\frac{1}{n-1} \cdot \sum_{i=1}^n (x_i - m)^2} \cong \sqrt{\frac{1}{n} \cdot \sum_{i=1}^n (x_i - \mu)^2}$$

estymator  
nieobciążony

**Transformacje rozkładów (to są tylko przykłady!):**

Logarytm ze zmiennej  
losowej (dodatniej!):

$$y = \log_e(x)$$

Funkcja wykładnicza (np.  
eksponenta) ze zmiennej  
losowej:

$$y = e^x$$



AGH

# Projektowanie generatorów o specjalnych rozkładach


Dystrybucja (CDF – cumulative density function):

$$F(x) = \int_{-\infty}^x f(t) dt$$

$$f(x) = \text{PDF}(x)$$

gdzie

```
...  
N=2^10; u=3; sigma=2;  
x=(rand(N,1)-0.5)*sqrt(12)*sigma+u;  
  
K=10;  
[hx,bx]=hist(x,K);  
hcx=cumsum(hx); % mozna zrobic samemu;  
  
figure(1); clf;  
bar(bx,hcx/hcx(end),1); grid on  
axis tight;  
...
```







# Projektowanie generatorów o specjalnych rozkładach (cd.)

Metoda ta może być stosowana dla rozkładów mających dystrybuantę, dla której można wyznaczyć funkcję odwrotną na przedziale, na którym rozkład jest niezerowy.

**Algorytm:**

1. Za pomocą generatora *rand* losujemy liczby z przedziału  $[0,1]$ , które traktujemy jak wartości z pionowej osi dystrybuanty.
2. Wyznaczamy (funkcją odwrotną do dystrybuanty) wartości na osi poziomej odpowiadające wylosowanym wartościom z osi pionowej.
3. Te wartości spełniają założony rozkład.



AGH


# Projektowanie generatorów o specjalnych rozkładach (cd.)

```
...  
N=2^16;  
x=rand(N,1);  
y=10.^x;  
  
K=30;  
[hy,by]=hist(y,K);  
hcy=cumsum(hy);
```


```
fs=12;  
figure(1); clf;  
    bar(by,hy,1);          grid on;  
                        set(gca,'fontsize',fs);  axis tight;  
  
figure(2); clf;  
    bar(by,hcy/hcy(end),1); grid on;  
    set(gca,'fontsize',fs); axis tight;
```

...

Histogram z próby



Dystrybuanta z próby






AGH


# Projektowanie generatorów o specjalnych rozkładach (cd.)

Zadanko do przemyslenia: jak tą metoda można otrzymać rozkłady  
np. trójkątne o zadanych parametrach?


Histogram z próby



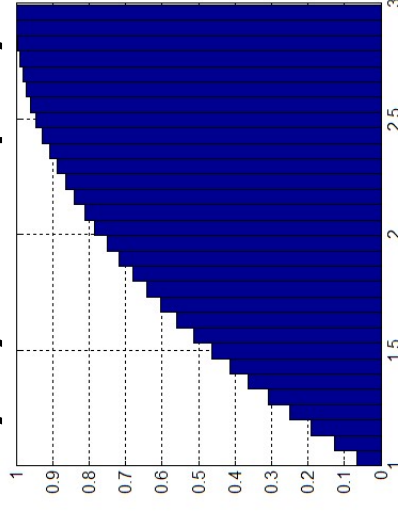
Dystrybuanta z próby



Histogram z próby



Dystrybuanta z próby





# Rozkłady prawdopodobieństwa

## AGH - dyskretne zmienne losowe

Np. równomierny rozkład prawdopodobieństwa dyskretnej zmiennej losowej:

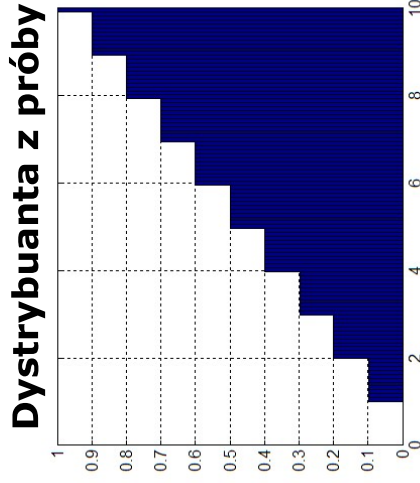

$$k = 1, 2, \dots, n : P(X = x_k) = \frac{1}{n}$$

```
...  
N=2^16;  
M=10;  
x=floor(rand(N,1)*M)+1;  
x(x>M)=M; % nadmiar ostroznosci?  
  
K=100;  
[hx,bx]=hist(x,K);  
hcx=cumsum(hx)/sum(hx);  
...
```

Inne funkcje zaokrąglające: **ceil**, **round**.

Można też użyć funkcji: **randi** (byle poprawnie!).

Niekiedy przydatna może być też funkcja: **randperm**.





AGH

# Klasyczne całkowitoliczbowe generatory pseudolosowe

Do generowania całkowitych, nieujemnych liczb losowych z przedziału  $[0, M)$  najczęściej stosowane są generatory kongruentne, liniowe działające według przepisu

$$x_{n+1} = \left( \sum_{m=0}^k a_m x_{n-m} \right) \bmod M$$

gdzie współczynniki kombinacji liniowej są liczbami całkowitymi wybranymi arbitralnie z zadanego przedziału  $[0, M)$

Np.: generatory dwumianowe:

$$x_{n+1} = (ax_{n-1} + b) \bmod M$$

... i dalej np.:

a) generatory Fibonacciego:

$$x_{n+1} = (x_n + x_{n-1}) \bmod M$$

...lub:

b) generatory mnożeniowe :  
(dla  $b$  różnego od zera!)

$$x_{n+1} = (bx_n) \bmod M$$

Matlab: **mod**, **rem** (uwaga – dla ujemnych argumentów wyniki mogą być różne)



AGH

# Dlaczego jest to generowanie pseudolosowe?

Można sprawdzić:

```
...  
N=4;  
for n=1:3  
    rng(2000); % random number generator: seed=2000;  
    X1(n,1:N)=rand(1,N);  
End  
  
    rng('shuffle'); % ustawia początek sekwencji na podst. zegara;  
for n=1:3  
    X2(n,1:N)=rand(1,N);  
end  
  
X1  
X2  
...
```



AGH

# Dlaczego rozkład normalny jest taki normalny?

Czyli: Centralne Twierdzenie Graniczne.

Jest kilka wersji tego twierdzenia, przy różnie sformułowanych założeniach. Generalnie istotne jest, by rozkłady składowe były „skupione”.

$$\lim_{N \rightarrow \infty} \left( \sum_{n=1}^N X_n(\mu_n, \sigma_n) \right) = X_{norm}(\mu, \sigma)$$

W praktyce liczba zmiennych losowych jest zwykle skończona, co daje przybliżony – np. obustronnie obcięty – rozkład Gaussa.

$$\text{np.:} \quad Y = \sum_{n=1}^N X_n(\mu_n, \sigma_n) \Rightarrow \mu_Y = \sum_{n=1}^N \mu_{X_n} \quad \wedge \quad \sigma_Y^2 = \sum_{n=1}^N \sigma_{X_n}^2$$

$$\text{lub:} \quad Y = \frac{1}{N} \cdot \sum_{n=1}^N X_n(\mu_n, \sigma_n) \Rightarrow \mu_Y = \frac{1}{N} \cdot \sum_{n=1}^N \mu_{X_n} \quad \wedge \quad \sigma_Y^2 = \frac{1}{N^2} \cdot \sum_{n=1}^N \sigma_{X_n}^2$$

## Efekt dla wartości średniej

**Dla takich samych rozkładów, czyli przy powtarzanym  $N$  razy niezależnym losowaniu z tej samej populacji:**

$$Y = \frac{1}{N} \cdot \sum_{n=1}^N X(\mu_X, \sigma_X) \Rightarrow \mu_Y = \mu_X \quad \wedge \quad \sigma_Y = \frac{\sigma_X}{\sqrt{N}}$$

**zmienna losowa = średnia z próby**



# Rozkład Gaussa

Rozkład Gaussa  
zmienniej losowej  $x$ :

$$f(x) = \frac{1}{\sigma \cdot \sqrt{2 \cdot \pi}} \cdot e^{\left( -\frac{(x-\mu)^2}{2 \cdot \sigma^2} \right)}$$

Standaryzacja  
zmienniej losowej:

$$X_0(0,1) = \frac{X(\mu, \sigma) - \mu}{\sigma}$$

lub odwrotnie:

$$X(\mu, \sigma) = X_0(0,1) \cdot \sigma + \mu$$

Matlab: **randn**, **normpdf**, **normcdf**, **norminv**.

# Rozkład Gaussa (cd.)

```

...
N=2^12;
u=3; sigma=2;
x=randn(N,1)*sigma+u;


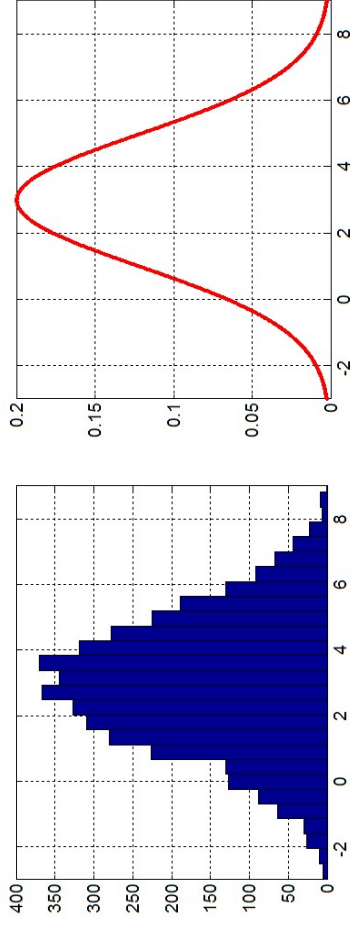
[hx,bx]=hist(x,30);
hcx=cumsum(hx)/sum(hx);

xx=u-3*sigma:6*sigma/1000:u+3*sigma;

xpdf = normpdf(xx,u,sigma);
xcdf = normcdf(xx,u,sigma);
xx2 = norminv(xcdf,u,sigma);

test_xxx=max(abs(xx-xx2)),
...

```



**Próba losowa:**

$$(x_n, y_n) \in \mathbf{R}^2 \quad : \quad n = 1, 2, \dots, N$$

$$D = \{(x_1, y_1), (x_2, y_2), (x_3, y_3), \dots, (x_N, y_N)\}$$

$$\mathbf{D} = \begin{bmatrix} x_1 & y_1 \\ x_2 & y_2 \\ x_3 & y_3 \\ \cdot & \cdot \\ x_N & y_N \end{bmatrix} = [\mathbf{x}, \mathbf{y}]$$

$$\mathbf{D}^T = \begin{bmatrix} x_1 & x_2 & x_3 & \dots & x_N \\ y_1 & y_2 & y_3 & \dots & y_N \end{bmatrix} = \begin{bmatrix} \mathbf{x}^T \\ \mathbf{y}^T \end{bmatrix}$$

## Regresja liniowa (cd.)

Zakładamy, że między wartościami  $x$  i  $y$  istnieje zależność matematyczna  
- model matematyczny tej zależności.  
Zakładamy, że ma on postać funkcji liniowej:

$$l(a_1, a_2): \quad y = a_1 \cdot x + a_2$$

Jeżeli wartości  $x$  możemy uznać za dokładne, to prostą regresji wyznaczamy minimalizując sumę kwadratów błędów liczonych jedynie w kierunku  $y$ :

$$\min_{a_1, a_2} \left( \sum_{n=1}^N [y_n - (a_1 \cdot x_n + a_2)]^2 \right)$$

## Regresja liniowa (cd.)

$$a_1 \cdot x_n + a_2 = y_n - e_n \quad : \quad n = 1, 2, \dots, N$$

$$\mathbf{X} \cdot \mathbf{a} = \mathbf{y} - \mathbf{e}$$

$$\begin{bmatrix} x_1 & 1 \\ x_2 & 1 \\ x_3 & 1 \\ \vdots & \vdots \\ x_{N-2} & 1 \\ x_{N-1} & 1 \\ x_N & 1 \end{bmatrix} \cdot \begin{bmatrix} a_1 \\ a_2 \end{bmatrix} = \begin{bmatrix} y_1 \\ y_2 \\ y_3 \\ \vdots \\ y_{N-2} \\ y_{N-1} \\ y_N \end{bmatrix} - \begin{bmatrix} e_1 \\ e_2 \\ e_3 \\ \vdots \\ e_{N-2} \\ e_{N-1} \\ e_N \end{bmatrix}$$

**Stosujemy macierz pseudoodwrotną:**

$$\mathbf{a} = \left( \mathbf{X}^T \cdot \mathbf{X} \right)^{-1} \cdot \mathbf{X}^T \cdot \mathbf{y}$$

# Regresja liniowa, wielowymiarowa

$$a_0 + a_1 \cdot x_{1,n} + a_2 \cdot x_{2,n} + a_3 \cdot x_{3,n} + \dots + a_K \cdot x_{K,n} = y_n - e_n$$
$$: \quad n = 1, 2, \dots, N$$

$$\mathbf{X} \cdot \mathbf{a} = \mathbf{y} - \mathbf{e}$$

**$N$  wektorowych wartości  $\mathbf{x}$ ;  $K$  elementów każdego wektora  $\mathbf{x}$ :**

$$\mathbf{x}_n = \begin{bmatrix} x_{1,n} \\ x_{2,n} \\ \vdots \\ x_{K,n} \end{bmatrix} \quad : \quad n = 1, 2, \dots, N$$

## Regresja liniowa, wielowymiarowa (cd.)

$$a_0 + a_1 \cdot x_{1,n} + a_2 \cdot x_{2,n} + a_3 \cdot x_{3,n} + \dots + a_K \cdot x_{K,n} = y_n - e_n$$

$$: \quad n = 1, 2, \dots, N$$

$$\mathbf{X} \cdot \mathbf{a} = \mathbf{y} - \mathbf{e}$$

$$\begin{bmatrix} 1 & x_{1,1} & x_{2,1} & \dots & x_{K,1} \\ 1 & x_{1,2} & x_{2,2} & \dots & x_{K,2} \\ 1 & x_{1,3} & x_{2,3} & \dots & x_{K,3} \\ \vdots & \vdots & \vdots & \vdots & \vdots \\ 1 & x_{1,N} & x_{2,N} & \dots & x_{K,N} \end{bmatrix} \cdot \begin{bmatrix} a_0 \\ a_1 \\ a_2 \\ \vdots \\ a_K \end{bmatrix} = \begin{bmatrix} y_1 \\ y_2 \\ y_3 \\ \vdots \\ y_{N-2} \\ y_{N-1} \\ y_N \end{bmatrix} - \begin{bmatrix} e_1 \\ e_2 \\ e_3 \\ \vdots \\ e_{N-2} \\ e_{N-1} \\ e_N \end{bmatrix}$$

**Stosujemy macierz pseudoodwrotną:**

$$\mathbf{a} = \left( \mathbf{X}^T \cdot \mathbf{X} \right)^{-1} \cdot \mathbf{X}^T \cdot \mathbf{y}$$

# Regresja nieliniowa

$$a_0 + a_1 \cdot g(x_n) = y_n - e_n \quad : \quad n = 1, 2, 3, \dots, N$$

$$\mathbf{X} \cdot \mathbf{a} = \mathbf{y} - \mathbf{e}$$

$$\begin{bmatrix} 1 & g(x_1) \\ 1 & g(x_2) \\ 1 & g(x_3) \\ \vdots & \vdots \\ 1 & g(x_{N-2}) \\ 1 & g(x_{N-1}) \\ 1 & g(x_N) \end{bmatrix} \cdot \begin{bmatrix} a_0 \\ a_1 \end{bmatrix} = \begin{bmatrix} y_1 \\ y_2 \\ y_3 \\ \vdots \\ y_{N-2} \\ y_{N-1} \\ y_N \end{bmatrix} - \begin{bmatrix} e_1 \\ e_2 \\ e_3 \\ \vdots \\ e_{N-2} \\ e_{N-1} \\ e_N \end{bmatrix}$$

**Stosujemy macierz pseudoodwrotną:**

$$\mathbf{a} = \left( \mathbf{X}^T \cdot \mathbf{X} \right)^{-1} \cdot \mathbf{X}^T \cdot \mathbf{y}$$



# Regresja nieliniowa, wielowymiarowa

$$a_0 \cdot g_0(x_n) + a_1 \cdot g_1(x_n) + a_2 \cdot g_2(x_n) + \dots + a_K \cdot g_K(x_n) = y_n - e_n$$
$$: \quad n = 1, 2, 3, \dots, N$$

$$\text{np.} : \quad g_0(x) = 1; \quad g_k(x) = \cos(2 \cdot \pi \cdot k \cdot f_0 \cdot x - \varphi_k) \quad , \quad k = 1, 2, \dots, K$$

$$\text{lub} : \quad g_k(x) = x^k \quad , \quad k = 0, 1, 2, \dots, K$$

# Regresja nieliniowa, wielowymiarowa (cd.)

$$a_0 \cdot g_0(x_n) + a_1 \cdot g_1(x_n) + a_2 \cdot g_2(x_n) + \dots + a_K \cdot g_K(x_n) = y_n - e_n$$

$$: \quad n = 1, 2, 3, \dots, N$$

$$\mathbf{X} \cdot \mathbf{a} = \mathbf{y} - \mathbf{e}$$


$$\begin{bmatrix} g_0(x_1) & g_1(x_1) & g_2(x_1) & \dots & g_K(x_1) \\ g_0(x_2) & g_1(x_2) & g_2(x_2) & \dots & g_K(x_2) \\ g_0(x_3) & g_1(x_3) & g_2(x_3) & \dots & g_K(x_3) \\ \vdots & \vdots & \vdots & \vdots & \vdots \\ g_0(x_N) & g_1(x_N) & g_2(x_N) & \dots & g_K(x_N) \end{bmatrix} \cdot \begin{bmatrix} a_0 \\ a_1 \\ a_2 \\ \vdots \\ a_K \end{bmatrix} = \begin{bmatrix} y_1 \\ y_2 \\ y_3 \\ \vdots \\ y_{N-2} \\ y_{N-1} \\ y_N \end{bmatrix} - \begin{bmatrix} e_1 \\ e_2 \\ e_3 \\ \vdots \\ e_{N-2} \\ e_{N-1} \\ e_N \end{bmatrix}$$

**Stosujemy macierz pseudoodwrotną:**

$$\mathbf{a} = \left( \mathbf{X}^T \cdot \mathbf{X} \right)^{-1} \cdot \mathbf{X}^T \cdot \mathbf{y}$$

# Przykład generowania danych testowych

```
...  
N=2^6;  
x=rand(N,1)*10+20;  
  
% wartości idealne:  
a0=[-3, 2];  
y0=a0(1)+a0(2)*x;  
  
% wynik bez szumu  
% "pomiarowego" ;  
  
% zmierzone wartości y (zaszumione):  
y=y0+randn(N,1)*5;  
% dokładamy  
% szum addytywny  
% gaussowski  
% o zerowej średniej ;  
...
```



# ***Zapraszam do laboratorium ...***